

Uniwersytet Jagielloński  
Wydział Fizyki, Astronomii i Informatyki Stosowanej

WYKORZYSTANIE SZTUCZNYCH SIECI  
NEURONOWYCH DO ANALIZY OBRAZÓW NA  
PRZYKŁADZIE KOSTKI DO GRY

Wojciech Ozimek

Nr albumu: 1124802

Praca wykonana pod kierunkiem  
prof. dr hab. Piotra Białasa  
kierownika Zakładu Technologii Gier  
FAIS UJ

kwiecień 2018

# Spis treści

|          |  |           |
|----------|--|-----------|
| <b>1</b> | <b>Wstęp</b>                               | <b>2</b>  |
| 1.1      | Biologiczny neuron . . . . .               | 2         |
| 1.2      | Sztuczny neuron . . . . .                  | 2         |
| 1.3      | Historia . . . . .                         | 3         |
| <b>2</b> | <b>Cel pracy</b>                           | <b>4</b>  |
| <b>3</b> | <b>Technologie</b>                         | <b>5</b>  |
| 3.1      | Język programowania i środowisko . . . . . | 5         |
| 3.2      | Biblioteki . . . . .                       | 5         |
| 3.3      | Technologie poza programistyczne . . . . . | 7         |
| <b>4</b> | <b>Słownik pojęć</b>                       | <b>8</b>  |
| <b>5</b> | <b>Proces tworzenia pracy</b>              | <b>13</b> |
| <b>6</b> | <b>Sieć neuronowa</b>                      | <b>14</b> |
| 6.1      | Czym jest sieć neuronowa . . . . .         | 14        |
| 6.2      | Konwolucyjna sieć neuronowa . . . . .      | 14        |

# Wstęp

## 1.1 Biologiczny neuron

Neuron to komórka nerwowa zdolna do przewodzenia i przetwarzania sygnału elektrycznego w którym zawarta jest informacja. Jest on podstawowym elementem układu nerwowego wszystkich zwierząt. Każdy neuron składa się z ciała komórki (soma, neurocyt) otaczającego jądro komórkowe, neurytu (akson) odpowiedzialny za przekazywanie informacji z ciała komórki do kolejnych neuronów oraz dendrytów służących do odbierania sygnałów i przesyłaniu ich do ciała komórkowego. Impuls elektryczny z jednego neuronu do drugiego przekazywany jest w synapsie, miejscu komunikacji danego neuronu z poprzednim. Synapsa składa się z części presynaptycznej (aksonu) i postsynaptycznej (dendrytu). Neuron przewodzi sygnał tylko w sytuacji kiedy suma potencjałów na wejściach od innych neuronów na jego dendrytach przekroczy określony poziom. W przeciwnym wypadku neuron nie przewodzi sygnału. Dodatkowo, zwiększenie potencjału na wejściach nie powoduje wzmocnienia potencjału na wyjściu neuronu.

Neurony połączone i działające w ten sposób tworzą sieci neuronowe, których dobrym przykładem może być mózg człowieka. Przeciętnie posiada on około 100 miliardów neuronów, każdy z nich połączony jest z około 10 tysiącami innych neuronów przez połączenia synaptyczne. Liczba połączeń synaptycznych szacowana jest na około  $10^{15}$ .

## 1.2 Sztuczny neuron

Matematycznym modelem neuronu jest tzw. neuron McCullocha-Pittsa, nazywany również neuronem binarnym. Jest to prosta koncepcja zakładająca, że każdy neuron posiada wiele wejść, z których każde ma przypisaną wagę w postaci liczby rzeczywistej oraz jedno wyjście. Wyjściem neuronu jest wartość funkcji aktywacji dla argumentu którym jest suma wszystkich wag pomnożonych przez odpowiednie wartości wejściowe. Wyjście danego neuronu połączone

jest z wejściami innych neuronów, tak jak ma to miejsce w przypadku biologicznego neuronu. Powyższy, sztuczny model neuronu jest podstawowym budulcem sztucznych sieci neuronowych z racji prostoty działania i łatwości implementacji. W rzeczywistych zastosowaniach używane są pojęcia takie jak wektor wejściowy oraz wektor wag, które oznaczają odpowiednio wszystkie wartości wejściowe oraz wszystkie wagi dla danego neuronu.

Pojedynczy neuron pozwala na uzyskanie mocno ograniczonych rozwiązań. Przykładowo korzystając z prostych funkcji logicznych AND, OR, NOT, XOR okazuje się że pojedynczy neuron jest w stanie poprawnie rozwiązywać jedynie pierwsze trzy z podanych funkcji. Problem wiąże się z brakiem możliwości uzyskania poprawnych rezultatów dla zbiorów które nie są liniowo separowalne. W takich przypadkach konieczne jest użycie większej ilości neuronów, a więc tworzenie sieci neuronowych których możliwości adaptacyjnego do poszczególnych problemów są niejednokrotnie bardzo zaskakujące.

## 1.3 Historia

Rozpoczęciem prac nad sztucznymi neuronami można datować na rok 1943 kiedy to Warren McCulloch i Walter Pitts przedstawili wspomniany już wcześniej model neuronu. Pierwsze sieci neurone używane były np do operacji bitowych i przewidywania kolejnych wystąpień bitów w ciągu. Mimo licznych prób zastosowania ich do realnych problemów nie zyskały one popularności. Powodem tego były prace naukowe sugerujące ograniczenia sieci takie jak brak możliwości rozszerzenia sieci do więcej niż jednej warstwy oraz jedynie jednokierunkowe połączenie między neuronami. W początkowym okresie rozwoju sieci neuronowych przyjmowano także wiele błędnych założeń które wraz z ograniczonymi możliwościami obliczeniowymi komputerów skutecznie zniechęcały naukowców do prac nad tym zagadnieniem.

Przełomem okazał się rok 1982 kiedy to John Hopfield przedstawił sieć asosjacyjną (zwaną siecią Hopfielda). Nowością było dwukierunkowe połączenie neuronów co zapewniało możliwość uczenia się danych wzorców. Kolejnymi przełomowymi odkryciami były zarówno wprowadzenie wielowarstwowych sieci neuronowych oraz wstecznej propagacji. Nowe odkrycia pozwoliły na zastosowanie sieci w wielu różnych dziedzinach, wymagając jednak dużych ilości obliczeń, obszernych zbiorów treningowych, wielu tysięcy iteracji i długiego czasu nauki. Korzyścią jest jednak fakt, że wytrenowany model można wykorzystać w praktycznie każdych warunkach i natychmiastowo bez konieczności uczenia.

# Cel pracy

Celem pracy jest stworzenie sieci neuronowej rozpoznającej ilość oczek wyrzuconych na kostce do gry. Sieć powinna rozpoznawać kostki o dowolnym zestawieniu kolorystycznym ścian oraz oczek i działać na rzeczywistym obrazie przesyłanym z kamery.

Dodatkowym aspektem poruszonym w pracy jest porównanie modeli w zależności od architektury sieci oraz zbiorów danych.

# Technologie

Poniższy spis przedstawia technologie użyte podczas tworzenia tej pracy licenckiej. Każda technologia jest krótko opisana wraz z powodem dla którego została użyta.

## 3.1 Język programowania i środowisko

### Python

Język programowania Python obecnie jest bardzo popularnym narzędziem wykorzystywanym w pracach naukowych. Jest to spowodowane bardzo czytelną i zwięzłą składnią, która w pełni pozwala skupić się na danym problemie. Jest on także używany w bibliotekach które wykorzystywane były do tworzenia modeli sieci neuronowych.

### Jupyter Notebook

Aplikacja Jupyter Notebook pozwala uruchamiać w przeglądarce pliki tzw. notebooki które składają się z wielu bloków. W blokach może znajdować się kod programu lub jego fragment, a w pozostałych można prezentować m.in. tekst, wykresy bądź tabele. Korzystanie z Jupyter Notebooka zdecydowanie ułatwia pracę, umożliwiając tworzenie kodu wraz z podglądem wykresów bądź danych prezentowanych w innej formie bez konieczności przełączania między oknami bądź kartami.

## 3.2 Biblioteki

### OpenCV

Biblioteka funkcji do obróbki obrazów, najczęściej wykorzystywana w języki C++ oraz Python. W projekcie została użyta do uzyskiwania zbiorów obrazów kości do gry ze zdjęć uzyskanych kamerą. Uzyskane zbiory charakteryzowały się ściśle określonymi wymiarami każdego z obrazów, obrotami obrazów o ściśle określony kąt, trybami RGB oraz monochromatycznym jak również

kadrowaniem w celu osiągnięcia zakładanych proporcji między wielkością kostki na zdjęciu a rozmiarem obrazu.

## **TensorFlow**

Biblioteka do uczenia maszynowego oraz tworzenia sieci neuronowych. Jej ogromną zaletą jest możliwość wykorzystywania zarówno procesorów jak i procesorów graficznych. Z uwagi na charakter wykonywanych obliczeń praca przy użyciu kart graficznych jest kilka razy szybsza niż na procesorze, co znacząco przyspiesza proces uczenia. Najlepiej wspierane języki programowania to C++ oraz Python.

## **Keras**

Biblioteka do tworzenia modeli sieci neuronowych wykorzystująca inne bardziej profesjonalne biblioteki jak TensorFlow, Theano lub CNTK. Zaletami Kerasa są zarówno przystępny interfejs pozwalający w krótkim czasie stworzyć model sieci oraz możliwość stworzenia zaawansowanych modeli przy średnim pogorszeniu czasu uczenia się sieci o 3-4% w stosunku do TensorFlow.

W sytuacji kiedy interfejs oraz dokumentacja do TensorFlow są dla początkującej osoby niezrozumiałe, jest to świetna alternatywa do wdrożenia się w to zagadnienie.

## **Numpy**

Moduł języka Python umożliwiający wykonywanie zaawansowanych operacji na macierzach oraz wektorach, wspierający liczne funkcje matematyczne. Jest bardzo rozpowszechniony, wykorzystywany w wielu, głównie naukowych zastosowaniach. Numpy wprowadza własne typy danych oraz funkcje które są niedostępne w instalacji Pythona. Może być rozbudowany o moduł Scipy, który nie był jednak wykorzystany przy tworzeniu tej pracy.

## **Matplotlib**

Narzędzie do tworzenia wykresów dla języka Python oraz modułu Numpy. Z uwagi na bardzo duże możliwości jest bardzo popularny, pozostając jednocześnie prostym w użyciu. Zawiera moduł pyplot który w założeniu ma maksymalnie przypominać interfejs w programie MATLAB.

## **LaTeX**

Oprogramowanie do organizacji tekstu wraz z językiem odpowiednich znaczników. Praca w LaTeX jest przeciwieństwem edytorów tekstowych typu WYSIWYG jak MSWord. LaTeX bazuje na TeX który jest systemem składu drukarskiego do prezentacji w formie graficznej. Ogromną zaletą jest możliwość tworzenia w tekście zaawansowanych wzorów matematycznych.

### 3.3 Technologie poza programistyczne

#### **NVIDIA CUDA**

Równoległa architektura obliczeniowa firmy NVIDIA pozwala na wielokrotne przyspieszenie obliczeń podczas uczenia się sieci neuronowych. Dzięki bibliotekom takim jak TensorFlow lub Keras, które wspierają obliczenia na kartach graficznych czas precesu uczenia drastycznie maleje. Podczas tej pracy wykorzystana została karta NVIDIA TESLA K80 12GB GPU dostępna na Amazon AWS oraz Google Compute Engine.

#### **Amazon AWS EC2**

Platforma z wirtualnymi maszynami zwanymi instancjami, które można dostosować zależnie od potrzeb klienta. Usługa działa na zasadzie rozliczenia godzinowego podczas korzystania z niej. W tej pracy zostały wykorzystane instancje zoptymalizowane do obliczeń na kartach graficznych i do uczenia maszynowego, wyposażone w wcześniej wspomnianą kartę NVIDIA TESLA K80.

#### **Google Compute Engine**

Platforma analogiczna do wyżej wspomnianej, dysponująca tymi samymi modelami kart. W pracy wykorzystywana mniej niż Amazon AWS, głównie z powodu przyzwyczajenia do tamtejszej strony. Dodatkowym celem było sprawdzenia czy różnica w oprogramowaniu serwerów będzie miała wpływ na szybkość nauki sieci neuronowych, co jednak nie znalazło potwierdzenia w praktyce. Wartym wspomnienia jest fakt, że na obu platformach czas trwania uczenia sieci zmniejszył się średnio 6-10 krotnie w stosunku do pracy na komputerze wykorzystującym procesor.



# Słownik pojęć

## Zbiór danych

Zbiór danych lub obrazów to zbiór wszystkich zdjęć kości wykonanych na poczet pracy z wykorzystaniem kamery. Każde zdjęcie w zbiorze jest przetworzone w celu zmniejszenia czasu uczenia się sieci oraz potrzebnej pamięci. Zdjęcia były wykonywane kamerą o rozdzielczości 1600x1200 pikseli. Każde ze zdjęć w zbiorze zostało poddane procesowi skalowania oraz kadrowania w celu osiągnięcia odpowiedniego rozmiaru. W celu uzyskania większej liczebności zbioru wszystkie obrazy zostały dodatkowo poddane operacji obrotu o dany kąt.

## Neuron

Najmniejszy element sieci neuronowej, przyjmuje wiele wejść i jedno wyjście. Może zawierać także próg (ang. threshold), który może być zmieniony przez funkcje uczącą. Neuron wyposażony jest także w funkcję aktywacji, odpowiednio modyfikującą jego wyjście. Każde wyjście neuronu z poprzedniej warstwy połączone jest z wejściami innych neuronów w warstwie następnej.

$$f(x_i) = \sum_i w_i x_i + b \quad (4.1)$$

## Wagi neuronu

Połączenia w sieci realizowane są między wyjściem poprzedniego neuronu  $i$  oraz wejściem następnego neuronu  $j$ . Każde takie połączenie ma przypisaną wartość wagi  $w_{ij}$ . Podczas procesu uczenia wagi zmieniają się, dostosowując sieć neuronową do otrzymywanych danych, co skutkuje zmniejszeniem wartości błędu.

## Warstwa

Sieć neuronowa zorganizowana jest w warstwach. Neurony w danej warstwie nie są ze sobą w żaden sposób połączone, komunikacja odbywa się tylko między kolejnymi warstwami. Istnieje wiele rodzajów warstw, a sygnał który przechodzi przez całą sieć zaczyna się w tzw. warstwie

wejściowej oraz kończy w tzw. warstwie wyjściowej. Istnieją sieci neuronowe (rekurencyjne sieci neuronowe, *ang. RNN - Recurrent Neural Network*) w których sygnał może przechodzić przez warstwy kilkakrotnie w trakcie jednej epoki.

## **Bias**

## **Rodzaje warstw**

Poniższe rodzaje warstw zostały użyte w modelach przedstawionych w tej pracy.

### **Wejściowa**

Input

### **Wyjściowa**

Output

### **Konwolucyjna**

Conv2D

### **Aktywacyjna**

Activation

### **W pełni połączona**

Fully connected

### **Flatten**

Flatten

### **Odrzucająca**

Dropout

### **MaxPooling**

MaxPooling2D

## Funkcja aktywacji

Przy pomocy funkcji aktywacji obliczana jest wartość wyjściowa neuronów w sieci neuronowej. Argumentem dostarczanym do funkcji aktywacji jest suma wejść neuronu pomnożonych przez przypisane im wartości wag. Zależnie od konkretnego rodzaju funkcji aktywacji, neuron po przekroczeniu danego progu wysyła sygnał wyjściowy, odbierany przez neurony znajdujące się w następnej warstwie.

$$f\left(\sum_i w_i x_i + b\right) \quad (4.2)$$

## Rodzaje funkcji aktywacji

Przedstawione poniżej funkcje aktywacji zostały użyte w modelach zaprezentowanych w tej pracy.

### Sigmoid

$$f(x) = \sigma(x) = \frac{1}{1 + e^{-x}} \quad (4.3)$$

### Tanh

$$f(x) = \tanh(x) = \frac{(e^x - e^{-x})}{(e^x + e^{-x})} \quad (4.4)$$

### ReLU

ReLU *and. Rectified linear unit* jest najpopularniejszą funkcją aktywacji wykorzystywaną w sieciach neuronowych. Zasadą tego jest szybki czas uczenia sieci bez znaczącego kosztu w postaci generalizacji dokładności.

$$f(x) = \begin{cases} x & \text{if } x > 0 \\ 0 & \text{if } x \leq 0 \end{cases} \quad (4.5)$$

### LeakyReLU

LeakyReLU jest ulepszeniem ReLU dzięki zastosowaniu niewielkiego gradientu w sytuacji dla której ReLU jest nieaktywne. Zmiana ta pozwala na uniknięcie problemu zanikających ReLU co objawiało się sprowadzeniem sporej części wyjść neuronów do zera.

$$f(x) = \begin{cases} x & \text{if } x > 0 \\ 0.01x & \text{if } x \leq 0 \end{cases} \quad (4.6)$$

## **Funkcja kosztu**

Funkcja kosztu lub funkcja błędu jest niezbędna do prawidłowego przeprowadzenia procesu uczenia. Daje ona informacje o różnicy między obecnym stanem sieci o optymalnym rozwiązaniem. Algorytm uczenia sieci analizuje wartość funkcji kosztu w kolejnych krokach w celu zminimalizowania jej.

## **Propagacja wsteczna**

Propagacja wsteczna lub wsteczna propagacja błędów *ang. Backpropagation* jest jednym z najskuteczniejszych algorytmów uczenia sieci neuronowych. Polega na minimalizacji funkcji kosztu korzystając z metody najszybszego spadku lub bardziej zoptymalizowanych sposobów, o których napisane jest w PARAGRAPH OPTYMALIZATORY. Swoją nazwę zawdzięcza sposobowi w jaki propagowane są te błędy, od warstwy wyjściowej do wejściowej.

## **Optymalizator**

**Stochastic Gradient Descent**

**RMSprop**

**Adam**

**Sieć neuronowa**

**Konwolucja**

**Filtr konwolucyjny**

**Konwolucyjna sieć neuronowa**

Paradygmaty uczenia

Epoka

Uczenie

Testowanie

Predykcja

# Proces tworzenia pracy

Wraz z postępem w tworzeniu pracy zmieniały się założenia oraz cele. Głównymi motywatorami zmian były postępy w tworzeniu zbiorów danych oraz samych modeli sieci

# Sieć neuronowa

## 6.1 Czym jest sieć neuronowa

## 6.2 Konwolucyjna sieć neuronowa